Suffix Array

WAKing

Olers'Chat

11th June, 2022

Contents

什么是后缀数组

什么是后缀数组

后缀数组就是把一个字符串所有的后缀按照字典序排序后排名为第 i 的后缀开头的位置形成的数组

什么是后缀数组

后缀数组就是把一个字符串所有的后缀按照字典序排序后排名为第 i 的后缀开头的位置形成的数组
例如 "abb" 的后缀数组就是 $[1, 3, 2]$

Contents

怎么求后缀数组

哈希

哈希

注意到我们可以利用哈希 + 二分在 $O(\log n)$ 的复杂度内求出两个串的最长公共前缀 lcp，然后比较后一位就可以判断出来两个串的大小

哈希

注意到我们可以利用哈希 + 二分在 $O(\log n)$ 的复杂度内求出两个串的最长公共前缀 lcp，然后比较后一位就可以判断出来两个串的大小
所以我们考虑用这个方式比较，然后用归并排序什么的就可以做到 $O(n\log^2 n)$ 求出后缀数组了

倍增

倍增

注意到如果我们要比较两个字符串 a 和 b，可以先比较 a 的前 k 位和 b 的前 k 位，如果不一样就可以直接确定，一样的话再比较后面的字符串

倍增

注意到如果我们要比较两个字符串 a 和 b，可以先比较 a 的前 k 位和 b 的前 k 位，如果不一样就可以直接确定，一样的话再比较后面的字符串
于是我们考虑倍增，首先先按照每一位的字符排个序，然后接下来进行 $\log n$ 轮排序，第 i 轮就是按照每个后缀的前 2^i 位排序，如果长度不到 2^i，后面用空字符替代

倍增

倍增

具体的，我们在第 $k+1$ 轮比较两个开始位置是 a 和 b 的后缀时，可以先比较在上一轮时的排名，如果相等，再去比较 $a+2^k$ 和 $b+2^k$ 的后缀在上一轮的排名

倍增

具体的，我们在第 $k+1$ 轮比较两个开始位置是 a 和 b 的后缀时，可以先比较在上一轮时的排名，如果相等，再去比较 $a+2^k$ 和 $b+2^k$ 的后缀在上一轮的排名

实际上容易发现我们第 $k+1$ 轮排序时就是以后缀 i 在上一轮的排名为第一关键字、后缀 $i+2^k$ 在上一轮的排名 (如果 $i+2^k$ 大于 n 的话排名就是 0) 为第二关键字排序

倍增

具体的，我们在第 $k+1$ 轮比较两个开始位置是 a 和 b 的后缀时，可以先比较在上一轮时的排名，如果相等，再去比较 $a+2^k$ 和 $b+2^k$ 的后缀在上一轮的排名

实际上容易发现我们第 $k+1$ 轮排序时就是以后缀 i 在上一轮的排名为第一关键字、后缀 $i+2^k$ 在上一轮的排名 (如果 $i+2^k$ 大于 n 的话排名就是 0) 为第二关键字排序

可以用基数排序做，时间复杂度 $O(n\log n)$

实现

实现

code

Contents

求了后缀数组有什么用？

Height 数组

Height 数组

Height

数组就是排名相邻的两个后缀的最长公共前缀，也就是 $\mathrm{Height}_i = \mathrm{lcp}\left(s\left[rk_{i-1}, rk_{i-1}+1, rk_{i-1}+2, \cdots, n\right], s\left[rk_i, rk_i+1, rk_i+2, \cdots, n\right]\right)$

Height 数组

Height

数组就是排名相邻的两个后缀的最长公共前缀，也就是 $\mathrm{Height}_i = \mathrm{lcp}\left(s\left[rk_{i-1}, rk_{i-1}+1, rk_{i-1}+2, \cdots, n\right], s\left[rk_i, rk_i+1, rk_i+2, \cdots, n\right]\right)$

特别的 $\mathrm{Height}_1 = 0$

Height 数组

Height

数组就是排名相邻的两个后缀的最长公共前缀，也就是 $\mathrm{Height}_i = \mathrm{lcp}\left(s\left[rk_{i-1}, rk_{i-1}+1, rk_{i-1}+2, \cdots, n\right], s\left[rk_i, rk_i+1, rk_i+2, \cdots, n\right]\right)$

特别的 $\mathrm{Height}_1 = 0$

定理：$\mathrm{Height}_{\mathrm{rk}_{i-1}} - 1 \leq \mathrm{Height}_{\mathrm{rk}_i}$

Height 数组

Height

数组就是排名相邻的两个后缀的最长公共前缀，也就是 $\mathrm{Height}_i = \mathrm{lcp}\left(s\left[rk_{i-1}, rk_{i-1}+1, rk_{i-1}+2, \cdots, n\right], s\left[rk_i, rk_i+1, rk_i+2, \cdots, n\right]\right)$

特别的 $\mathrm{Height}_1 = 0$

定理： $\mathrm{Height}_{\mathrm{rk}_{i-1}} - 1 \leq \mathrm{Height}_{\mathrm{rk}_i}$

证明懒得写了，见 oi-wiki

Height 数组

Height
数组就是排名相邻的两个后缀的最长公共前缀，也就是 $\mathrm{Height}_i = \mathrm{lcp}\left(s\left[rk_{i-1}, rk_{i-1}+1, rk_{i-1}+2, \cdots, n\right], s\left[rk_i, rk_i+1, rk_i+2, \cdots, n\right]\right)$
特别的 $\mathrm{Height}_1 = 0$
定理： $\mathrm{Height}_{\mathrm{rk}_{i-1}} - 1 \leq \mathrm{Height}_{\mathrm{rk}_i}$
证明懒得写了，见 oi-wiki
利用上面的定理，直接暴力去做就可以做到线性求出 Height **数组**

任意两个后缀的 lcp

任意两个后缀的 lcp

容易注意到

$$\operatorname{lcp}\left(s\left[a, a+1, a+2, \cdots, n\right], s\left[b, b+1, b+2, \cdots, n\right]\right) = \min_{k=\mathrm{rk}_a+1}^{\mathrm{rk}_b} \mathrm{Height}_k$$

任意两个后缀的 lcp

容易注意到

$$\mathrm{lcp}\left(s\left[a, a+1, a+2, \cdots, n\right], s\left[b, b+1, b+2, \cdots, n\right]\right) = \min_{k=\mathrm{rk}_a+1}^{\mathrm{rk}_b} \mathrm{Height}_k$$

所以可以转成 RMQ 问题，用四毛子算法解决就行了